

京东的基于langchain的知识问答和数据分析流程的开发：

- 京东的基于langchain的知识问答和数据分析流程的开发：

- 开发一个结合数据库查询和自然语言处理能力的智能聊天机器人，以便用户通过自然语言，查询结构化数据。
- 系统维护两类数据
 - 结构化数据：保存在 MySQL。
 - 文档类数据：以 Embedding 存入 Faiss 向量库。
- 首先要对于结构化表元数据生成M-Schema 元数据：将表结构转为半结构描述（数据库、表、列、类型、主键/外键、列描述与示例值等），统一作为 schema 的权威来源。
 - 例子

```
M-Schema
[DB_ID] superhero
[Schema]
# Table: hero_power
[
(hero_id:INTEGER, Primary Key, the id of the hero
Maps to superhero(id), Examples: [1, 2, 3]),
(power_id:INTEGER, the id of the power
Maps to superpower(id), Examples: [1, 18, 26])
]
# Table: superpower
[
(id:INTEGER, Primary Key, the unique identifier of the
superpower, Examples: [1, 2, 3]),
(power_name:TEXT, the superpower name, Examples:
[Agility, Accelerated Healing, Lantern Power Ring])
]
【Foreign keys】
hero_power.power_id=superpower.id
```

- 意图识别，最重要的环节，正确率瓶颈
 - 收到用户问题后，先做意图判断：知识问答 or 数据查询。
 - 使用Schema 感知
 - schema感知：词表加向量索引
 - 词表
 - 把业务里会出现的规范名及它们的同义词、别名、缩写整理成一个映射表
 - 比如：把“成交额/交易额/GMV”都归一到 GMV
 - 计算“命中率”（问题里有多少词能对上库内实体）

- 向量索引：把M-schema元数据通过embedding 模型保存到vector store，计算“语义相似度”
- 然后把（词表命中率）和（向量最大相似度）结合来得到一个Text2SQL 的概率
 - 大于60%，走text2sql,
- 对话记忆（Chat Memory）
 - 采用 Redis 记录最近 100 条消息（含 user/assistant）,
 - 作为 chat_history 注入到意图识别、问题改写与生成阶段，沿用已确认的时间范围/口径/维度等默认参数。
- 若判定为知识问答（RAG链路）：
 - 在向量库中多路召回：bge Embedding 相似度 + BM25 关键词检索并行执行，按预设权重融合打分，取前 Top-N 语义相关块。
 - 将「用户问题 + Top-N 检索结果 + chat_history」一并发送给大模型，生成自然语言回答（可附来源段落）。
- 若判定为数据查询（Text2SQL 链路）：
 - 和文档类数据不用同一个向量库，避免污染召回结果
 - M-Schema 元数据：将表结构转为半结构描述（表、列、类型、主键/外键、列描述与示例值等），统一作为 schema 的权威来源。
 - Schema 向量筛选：基于 Embedding 相似度，先识别与本问题最相关的表/列，只把这部分 M-Schema 子集 注入 Prompt，避免把全库元数据塞进模型，降低上下文负担。
 - ReAct 代理 + 自我改正：
 - prompt工程：设置sql具体方言，拦截敏感词（DDL），以及全表扫描的时候只返回前 100行
 - 采用 ReAct 模式
 - 生成 SQL 前先给出【计划】（涉及的表、Join 路径、过滤条件、聚合口径）。
 - 生成后做【自我检查】（列名/表名是否存在、主外键是否正确、是否包含必要 WHERE 以避免全表扫描、是否需要 DISTINCT/NULL 处理等）。
 - 执行报错或结果异常时，根据报错信息进行【自我改正】并自动重试
 - 设置重试次数，超过则返回知识问答
 - 结果生成：将查询结果 + 元数据说明 + 用户问题语境（含 chat_history）再次组织 Prompt，经 LCEL 链式 workflow 输出结构化结论 + NLP 解读